

Algorithmes d'apprentissage

non supervisé

01-03

Regroupement hiérarchique

Au programme

- Introduction
- Dendrogramme
- Où couper un dendrogramme ?
- Mesure de similarité
- Algorithme de regroupement hiérarchique
- Regroupement hiérarchique avec scikit-learn
- Ateliers
- Lectures et références

Introduction

Rappel des principaux types de partitionnement


- Partitionnement basé sur
 - les centroïdes (K-moyennes, CURE, ...)
 - la connectivité (hiérarchique, ...)
 - la distribution (BFR, ...)
 - la densité (DBSCAN, OPTICS, ...)
 - les grilles
- Et d'autres

Rappel des principaux types de partitionnement

- Partitionnement basé sur
 - les centroïdes (K-moyennes, CURE, ...)
 - la connectivité (**hiérarchique**, ...) ➡ On parle alors de **regroupement hiérarchique**
 - la distribution (BFR, ...)
 - la densité (DBSCAN, OPTICS, ...)
 - les grilles
- Et d'autres


K-moyennes, choix de K

- Le partitionnement basé sur les *K*-moyennes nécessite de spécifier le **nombre de clusters K**
- Ceci est un **inconvénient** car il n'existe pas de méthode “universelle” et robuste pour le **choix** de K
- Le **regroupement hiérarchique** est une technique de partitionnement alternative à l'algorithme des *K*-moyennes ne nécessitant pas le choix préalable du nombre de clusters




Regroupement hiérarchique

- Nous allons décrire ici le regroupement hiérarchique de type **agglomératif** (ou ascendant / bottom-up)
- Il s'agit du type le plus **courant** de regroupement hiérarchique
- Réfère au fait qu'un **dendrogramme** est construit à partir des observations (**feuilles**) en combinant successivement les clusters obtenus jusqu'à la **racine** (arbre / hiérarchie)




Regroupement hiérarchique

- Nous allons décrire ici le regroupement hiérarchique de type **agglomératif** (ou ascendant / bottom-up)
- Il s'agit du type le plus **courant** de regroupement hiérarchique
- Réfère au fait qu'un **dendrogramme** est construit à partir des observations (**feuilles**) en combinant successivement les clusters obtenus jusqu'à la **racine** (arbre / hiérarchie)



Regroupement hiérarchique


- Nous allons décrire ici le regroupement hiérarchique de type **agglomératif** (ou ascendant / bottom-up)
- Il s'agit du type le plus **courant** de regroupement hiérarchique
- Réfère au fait qu'un **dendrogramme** est construit à partir des observations (**feuilles**) en combinant successivement les clusters obtenus jusqu'à la **racine** (arbre / hiérarchie)



Les deux observations / clusters les plus proches sont regroupées en un cluster

Regroupement hiérarchique


- Nous allons décrire ici le regroupement hiérarchique de type **agglomératif** (ou ascendant / bottom-up)
- Il s'agit du type le plus **courant** de regroupement hiérarchique
- Réfère au fait qu'un **dendrogramme** est construit à partir des observations (**feuilles**) en combinant successivement les clusters obtenus jusqu'à la **racine** (arbre / hiérarchie)



Les deux clusters les plus proches sont regroupées en un cluster

Regroupement hiérarchique


- Nous allons décrire ici le regroupement hiérarchique de type **agglomératif** (ou ascendant / bottom-up)
- Il s'agit du type le plus **courant** de regroupement hiérarchique
- Réfère au fait qu'un **dendrogramme** est construit à partir des observations (**feuilles**) en combinant successivement les clusters obtenus jusqu'à la **racine** (arbre / hiérarchie)



Les deux clusters les plus proches sont regroupées en un cluster

Regroupement hiérarchique


- Nous allons décrire ici le regroupement hiérarchique de type **agglomératif** (ou ascendant / bottom-up)
- Il s'agit du type le plus **courant** de regroupement hiérarchique
- Réfère au fait qu'un **dendrogramme** est construit à partir des observations (**feuilles**) en combinant successivement les clusters obtenus jusqu'à la **racine** (arbre / hiérarchie)



Au final, un seul cluster (racine) contenant toutes les observations est obtenu

Regroupement hiérarchique


- Nous allons décrire ici le regroupement hiérarchique de type **agglomératif** (ou ascendant / bottom-up)
- Il s'agit du type le plus **courant** de regroupement hiérarchique
- Réfère au fait qu'un **dendrogramme** est construit à partir des observations (**feuilles**) en combinant successivement les clusters obtenus jusqu'à la **racine** (arbre / hiérarchie)



Les regroupements successifs permettent d'obtenir le **dendrogramme**

Dendrogramme

Dendrogramme



Clusters initiaux: A C B D E

Dendrogramme





Dendrogramme



Dendrogramme




Dendrogramme




Le dendrogramme complet est obtenu lorsque toutes les observations appartiennent au même cluster

Coupure du dendrogramme




Coupure du dendrogramme




Coupure du dendrogramme

Coupure à
2 clusters




Exemple avec des données simulées



Extrait de [2] - 45 observations simulées dans une espace 2D

Exemple avec des données simulées




Extrait de [2] - Dendrogramme obtenu par regroupement hiérarchique (saut maximum) et seuil de coupure

Où couper un dendrogramme ?



Où couper un dendrogramme ?




- Identifier les plus grandes distances de fusion (grands sauts).
- Choisir une hauteur juste avant un saut important.
- Utiliser des méthodes quantitatives (plus tard)
- Ajuster en fonction de l'objectif métier.

Mesure de similarité

Mesure de similarité

- La mesure de similarité la plus souvent rencontrée est la **distance euclidienne**
- Il y a une analogie forte entre **distance** et **similarité**. En effet
 - Des observations proches dans l'espace sont considérés plus similaires que des observations éloignées
 - Plus la distance augmente, plus les observations diffèrent, et donc plus la similarité diminue
- Il existe de nombreuses mesures de similarité, qui seront étudiées au fur et à mesure du cours
- Plusieurs critères peuvent être utilisés pour calculer la similarité: **saut minimum, saut maximum, lien moyen et distance de Ward**

Saut minimum, lien moyen et saut maximum




**Saut minimum
(simple link)**

**Lien moyen
(average link)**

**Saut maximum
(complete link)**

Distance de Ward (ou centroïde)


- La **distance de Ward** minimise la somme des carrés des différences à l'intérieur d'un cluster lors de la fusion
- Approche similaire à la fonction de coût de l'algorithme des K -moyennes
- **Applicable aux espaces euclidiens seulement**



Similarité selon les critères (1/2)

Lien	Similarité
Saut maximum	Maximale inter-clusters
Saut minimum	Minimale inter-clusters
Lien moyen	Moyenne inter-clusters
Ward / Centroïde	Entre les centroïdes de deux clusters

Similarité selon les critères (2/2)



<https://scikit-learn.org/stable/modules/clustering.html#hierarchical-clustering>

Algorithme de regroupement hiérarchique

Algorithme de regroupement hiérarchique


- Comparativement aux K -moyennes, l'algorithme de regroupement hiérarchique est relativement simple. Voici le pseudo-code

Démarrer avec un cluster par observation

Répéter {


Fusionner les deux clusters les plus similaires

} jusqu'à ce que toutes les observations appartiennent à un seul et même cluster



Regroupement hiérarchique avec scikit-learn

AgglomerativeClustering (scikit-learn 1.8)



Ateliers




<https://github.com/mswawola-cegep/420-a58-sf-gr-12022-hiver-2026.git>

01-03

Lectures et références

Lectures



- Introduction to Statistical Learning with Applications in R
Second edition (2021)
→ 12.4 Clustering Methods

Références

- [1] CS229: Machine Learning - Stanford University
- [2] [Gareth James, Daniela Witten, Trevor Hastie and Robert Tibshirani](#), “Introduction to Statistical Learning with Applications in R - Second edition”