Algorithmes d’apprentissage non supervisé

02-01

Recherche des plus proches voisins

@ 2026 MKL.AI - Tous droits réservés.

Au programme

- Recherche de documents
- Recherche des plus proches voisins
- Algorithme 1-NN (exhaustif / brute-force)
- Algorithme k-NN (exhaustif / brute-force)
- k-NN avec scikit-learn
- Questions ouvertes
- Lectures et références

@ 2026 MKL.AI - Tous droits réservés.

Recherche de documents

Recherche de documents

- Commençons par un exemple: vous êtes présentement en train de lire un article sur le soccer ...

Vous souhaitez trouver des articles **similaires**

@ 2026 MKL.AI - Tous droits réservés.

Recherche de documents

- Commençons par un exemple: vous êtes présentement en train de lire un article sur le soccer ...

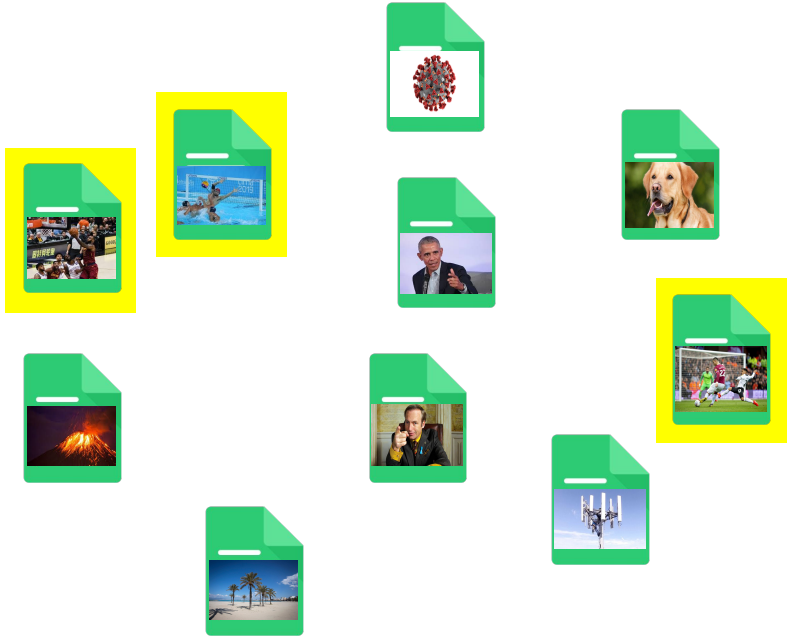

@ 2026 MKL.AI - Tous droits réservés.

Recherche de documents

- Commençons par un exemple: vous êtes présentement en train de lire un article sur le soccer ...

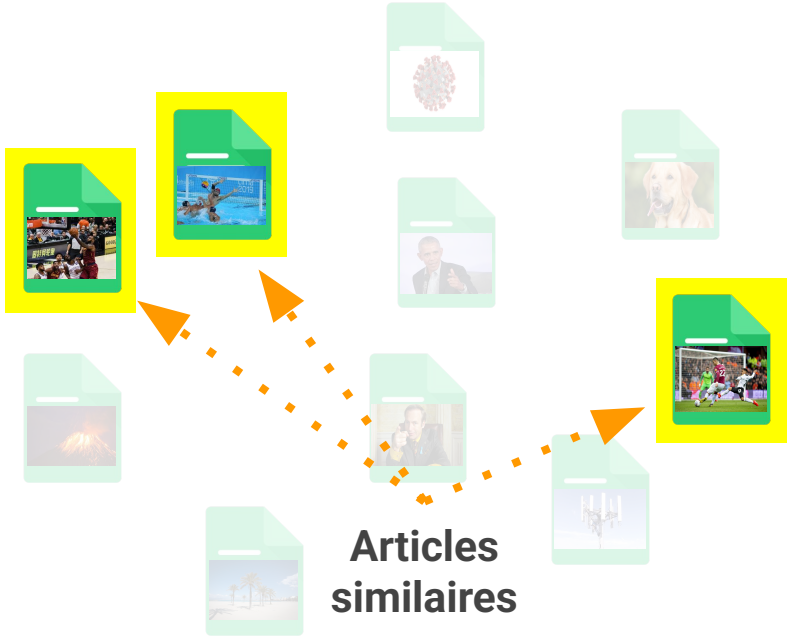

@ 2026 MKL.AI - Tous droits réservés.

Recherche de documents

- Commençons par un exemple: vous êtes présentement en train de lire un article sur le soccer ...

Comment **chercher** parmi tous les **documents** disponibles ?

Comment **mesurer la similarité** ?

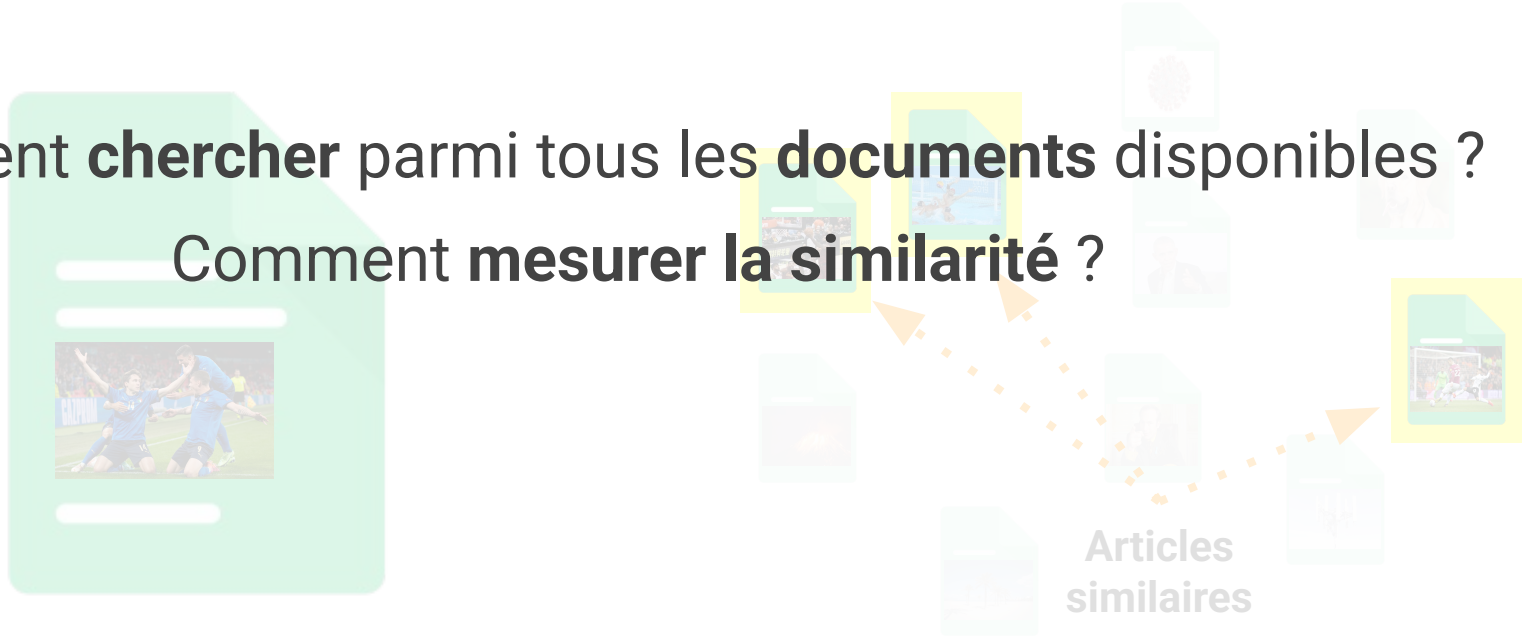

@ 2026 MKL.AI - Tous droits réservés.

Recherche des plus proches voisins

Recherche 1-NN

- Ci-dessous est représenté l’espace de tous les documents organisés par **similarité du texte**

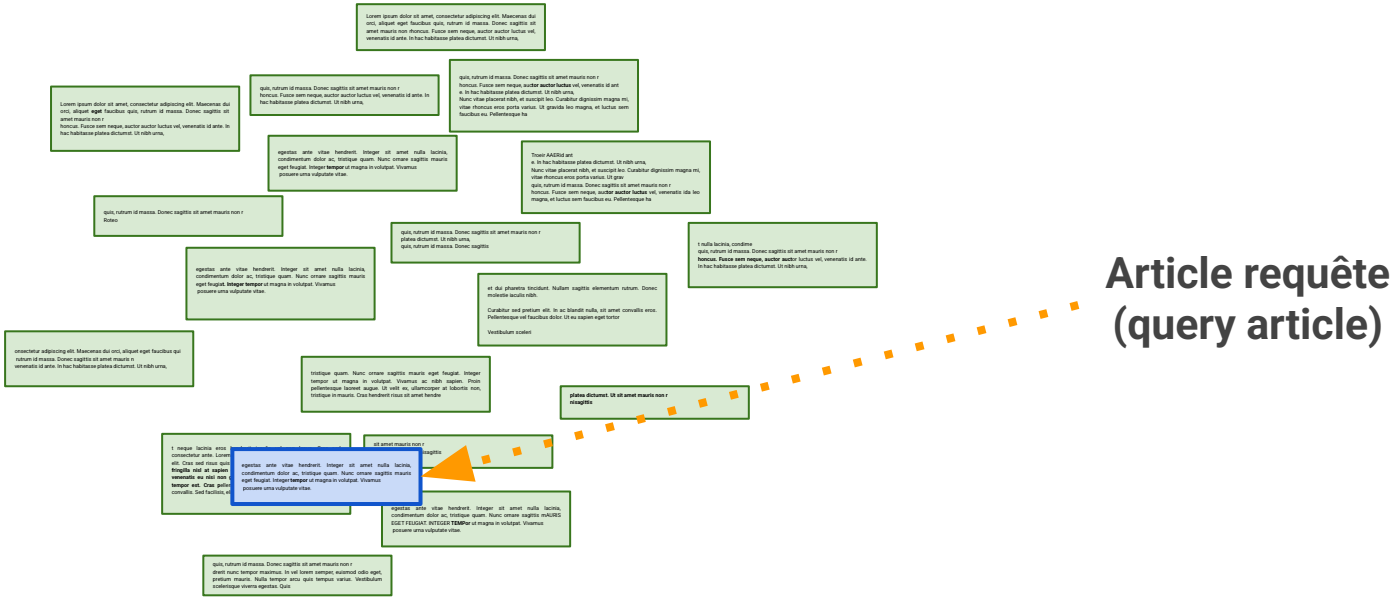

@ 2026 MKL.AI - Tous droits réservés.

Recherche 1-NN

- On calcul de la **distance** vers tous les documents

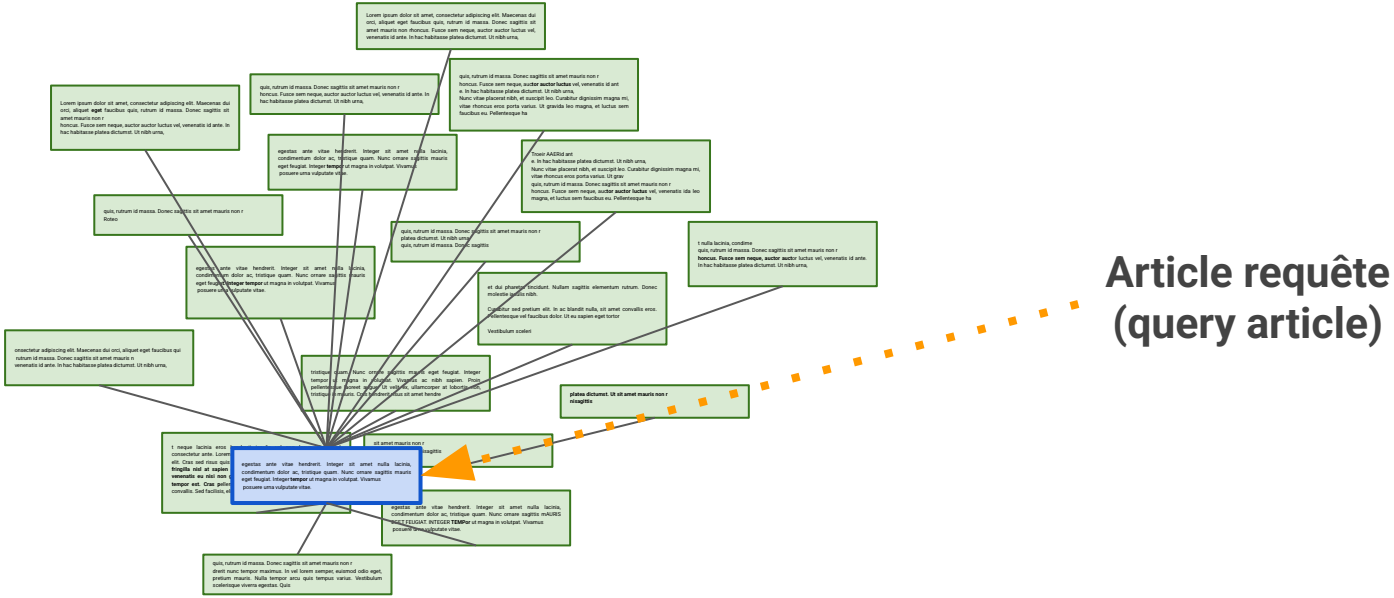

@ 2026 MKL.AI - Tous droits réservés.

Recherche 1-NN

- Identification du **plus proche voisin**

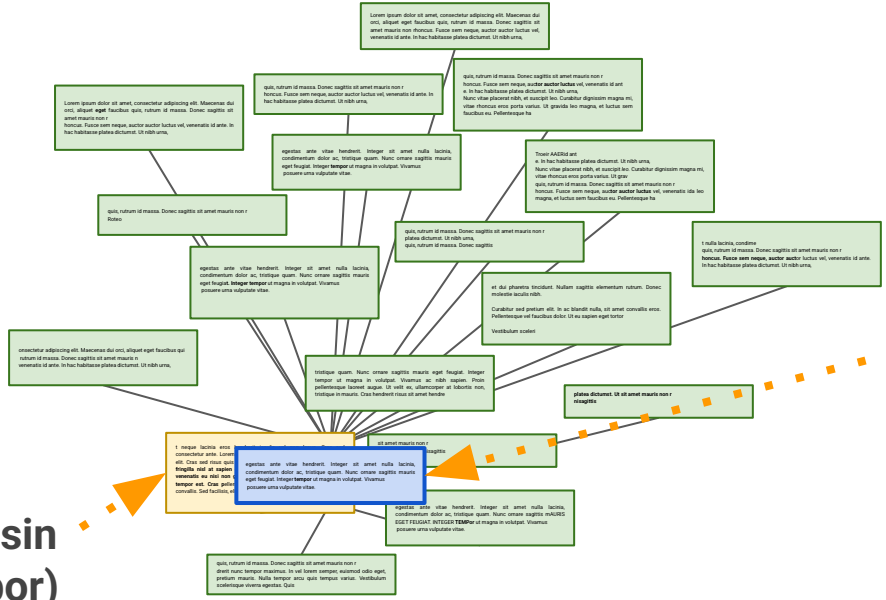

Article requête (query article)

Plus proche voisin (nearest neighbor)

@ 2026 MKL.AI - Tous droits réservés.

Recherche k-NN

- Identification d’un ensemble de **plus proches voisins**

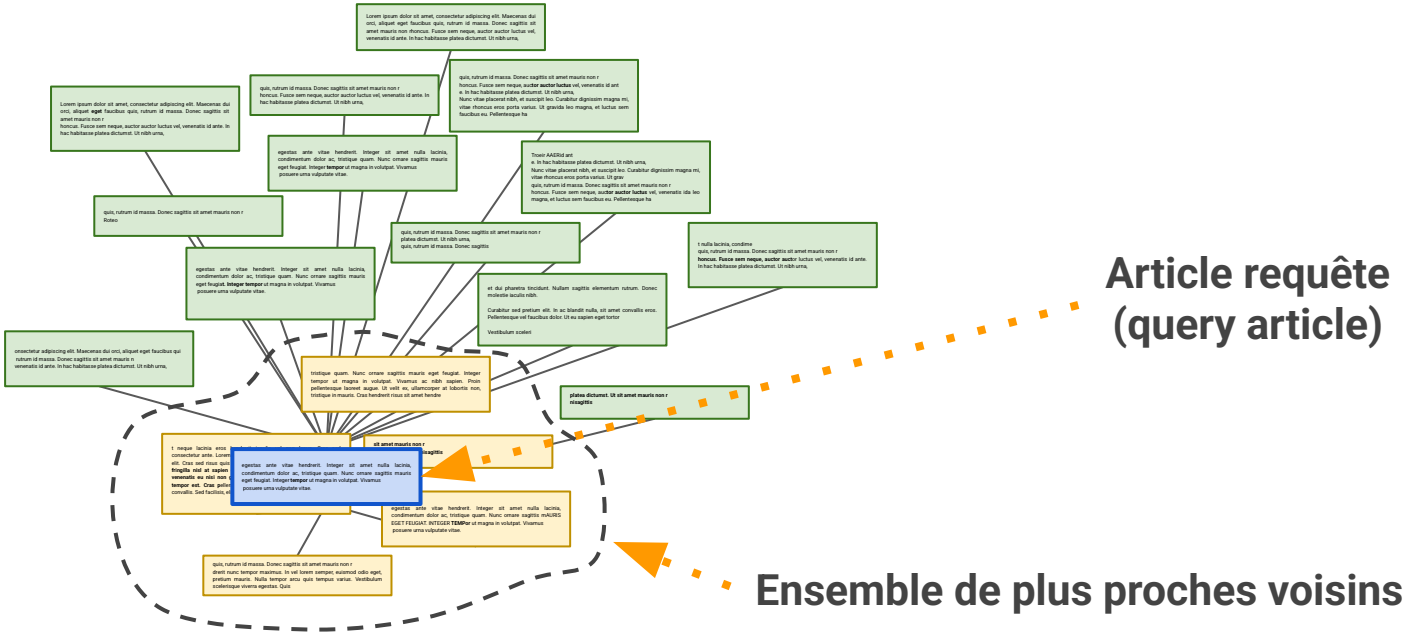

@ 2026 MKL.AI - Tous droits réservés.

k-NN: comparaison supervisé / non supervisé

Apprentissage supervisé

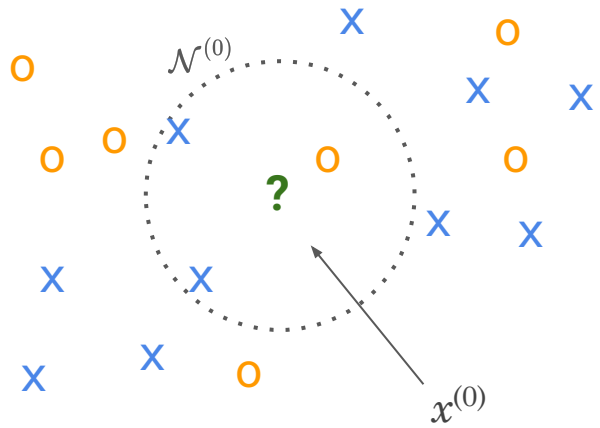

Apprentissage non supervisé

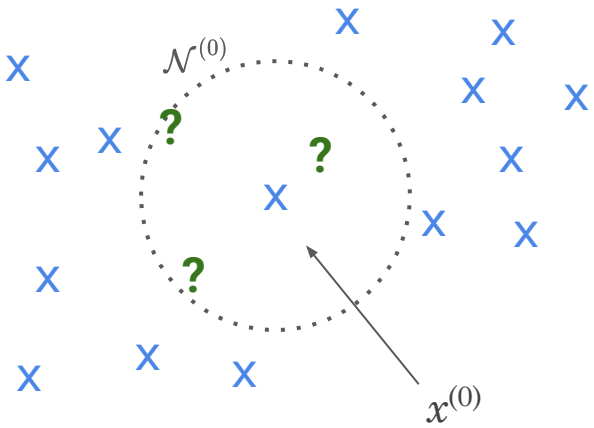

@ 2026 MKL.AI - Tous droits réservés.

Algorithme 1-NN (exhaustif / brute-force)

Algorithme 1-NN: notations

- **Entrée:**
  - Document “query”: x_q
  - Corpus de documents: $x_1, x_2, \ldots, x_M$
- **Sortie:**
  - Document le plus similaire: x^{NN}
- Formellement, nous cherchons le document x_i ayant la distance minimale avec x_q

$$x^{NN} = \min_{x_i} \text{distance}(x_q, x_i)$$

@ 2026 MKL.AI - Tous droits réservés.

Algorithme 1-NN: pseudo-code

Initialiser Dist2NN = ∞, x^{NN} = ∅

Itérer sur tous les documents x_1, x_2, …, x_M:

    Calculer la distance δ entre x_q et x_i

    Si δ < Dist2NN

        $x^{NN} = x_i$

        Dist2NN = δ

Retourner le document le plus similaire x^{NN}
(document du corpus le plus proche de x_q)

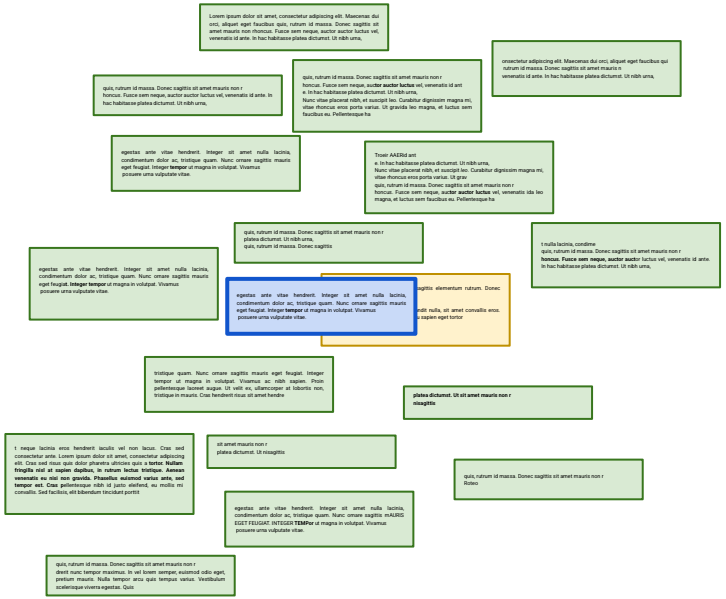

@ 2026 MKL.AI - Tous droits réservés.

Algorithme k-NN (exhaustif / brute-force)

Algorithme k-NN

- **Entrée:**
  - Document “query”: x_q
  - Corpus de documents: $x_1, x_2, \ldots, x_M$
- **Sortie:**
  - Liste des k documents les plus similaires: $X^{NN} = \{ x^{NN1}, x^{NN2}, \ldots, x^{NNk} \}$
- Formellement, nous cherchons tous les documents x_i tels que

$$\forall x_i \notin X^{NN}, \text{distance}(x_q, x_i) \geq \max_{x_i^{NNj}, j=1\ldots,k} \text{distance}(x_q, x^{NNj})$$

@ 2026 MKL.AI - Tous droits réservés.

Algorithme k-NN

```
Initialiser Dist2kNN = sort(δ1, δ2, …, δk)

Itérer sur tous les documents de k+1 à M: xk+1, …, xM:

    Calculer la distance δ entre xq et xi

    Si  δ < Dist2kNN[k]

        Trouver j tel que δ > Dist2kNN[j-1] et δ < Dist2kNN[j]

        Retirer le document le plus loin et déplacer les autres

        Dist2kNN[j+1:k] = Dist2kNN[j:k-1]

        Dist2kNN[j] = δ

Retourne les k documents les plus similaires
```

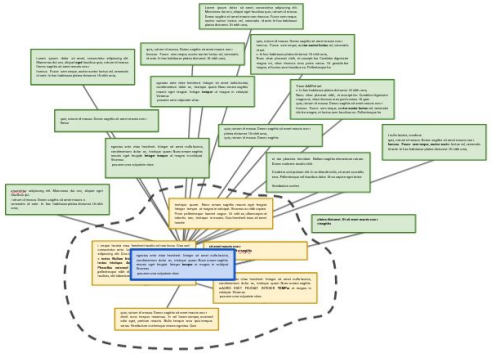

Trier les k premiers documents selon leur distance au document “query”

@ 2026 MKL.AI - Tous droits réservés.

Algorithme k-NN

```
Initialiser Dist2kNN = sort(δ1, δ2, …, δk)
Itérer sur tous les documents de k+1 à M: xk+1, …, xM:
    Calculer la distance δ entre xq et xi
    Si  δ < Dist2kNN[k]
        Trouver j tel que δ > Dist2kNN[j-1] et δ < Dist2kNN[j]
        Retirer le document le plus loin et déplacer les autres
        Dist2kNN[j+1:k] = Dist2kNN[j:k-1]
        Dist2kNN[j] = δ
Retourne les k documents les plus similaires
```

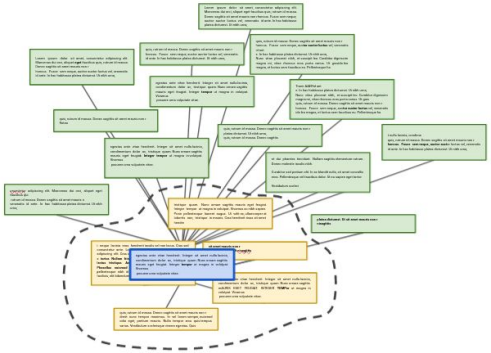

Insertion du document

@ 2026 MKL.AI - Tous droits réservés.

k-NN avec scikit-learn

NearestNeighbors (scikit-learn 1.2.2)

Nombre de voisins

Rayon de recherche

*class sklearn.neighbors.**NearestNeighbors**(*, **n_neighbors=5**, **radius=1.0**, **algorithm='auto'**, leaf_size=30, **metric='minkowski'**, **p=2**, metric_params=None, n_jobs=None)*

Algorithme de recherche

Métrique de distance

@ 2026 MKL.AI - Tous droits réservés.

Questions ouvertes

Questions ouvertes

- Comment représenter les documents ? $\rightarrow x_q$
- Quelle mesure utiliser pour calculer la distance entre les documents ? δ = **distance** (x_i, x_q)

@ 2026 MKL.AI - Tous droits réservés.

Lectures et références

Références

[1] Machine Learning: Clustering and Retrieval - Emily Fox & Carlos Guestrin - University of Washington

@ 2026 MKL.AI - Tous droits réservés.